UNIVERSIDAD NACIONAL DEL ALTIPLANO – PUNO | Facultad de Ingeniería Estadística e Informática

Informe técnico: selección del modelo para predecir el gasto turístico en Puno

Milton Flores Flores (231210) | Dataset `turismo_puno_2019_2024.csv` (2 484 registros) | Puno, noviembre de 2026

Objetivo. Elegir, con criterios explícitos y verificables, el modelo de regresión para predecir `gasto_promedio_soles` (gasto promedio por turista, en soles) a partir de 13 predictores: sitio, año, mes, temporada, festividad, nacionalidad, visitantes, clima, satisfacción y transporte. La selección siguió siete pasos (EDA → corrección → LazyPredict → validación → significancia → robustez → decisión). Semilla 42 en todo el proceso.

1. Paso 1. Lo que el EDA anticipa para la selección

- **Un solo predictor relevante:** la nacionalidad explica el 74 % de la varianza del gasto ($\eta^2 = 0{,}740$; ANOVA $F = 1409$, $p < 0{,}001$). Las demás variables tienen $\eta^2 < 0{,}002$ y $p > 0{,}36$. Las 15 diferencias entre pares de nacionalidades son significativas (Games-Howell, $p < 10^{-12}$).
- **Techo de predicción:** el ruido es multiplicativo, con coeficiente de variación constante (CV = 17,2 %) en todos los grupos. El R^2 máximo alcanzable es $R^2_{\text{máx}} = V_{entre}/(V_{entre} + V_{dentro}) = 0{,}743$. En 2 000 simulaciones Monte Carlo, el modelo ideal obtiene 0,741 (95 %: 0,709–0,771).
- **Implicación:** la relación es aditiva y simple, sin interacciones (ANOVA de dos vías con HC3; ninguna significativa tras Bonferroni), así que se esperan ganadores *lineales* y modelos flexibles propensos a sobreajustar.

2. Paso 2. Corrección del preprocesamiento antes de comparar

En la primera ejecución, `pd.get_dummies()` creó 21 columnas `bool` que LazyPredict 0.2.x descartó: los modelos entrenaron con 7 variables, **sin la nacionalidad**, y el mejor R^2 fue 0,003 (el log de LightGBM indicaba *used features: 7*). Se corrigió con `pd.get_dummies(drop_first=True, dtype=int)`, que da 28 predictores, y se añadió un *assert* defensivo (`verificar_X`) que exige que no haya columnas `bool` ni nulos antes de llamar a LazyPredict. Sin este paso, cualquier selección habría sido inválida.

3. Paso 3. Screening con LazyPredict (42 regresores, partición 80/20)

LazyRegressor entrenó 42 modelos con hiperparámetros por defecto en unos 6 s. Veinte superaron $R^2 = 0{,}70$. La Tabla 1 muestra el mejor de cada familia y la línea base.

Tabla 1: Screening de LazyPredict en el conjunto de prueba ($n = 497$)

Pos.	Modelo	Familia	R^2	RMSE (S/)	Tiempo (s)
1	OrthogonalMatchingPursuitCV	Lineal (selección de variables)	0,730	16,27	0,017
3	LassoCV	Lineal regularizado	0,728	16,35	0,056
7	LinearRegression	Lineal (MCO)	0,727	16,38	0,012
19	GradientBoostingRegressor	Ensamble de árboles	0,717	16,67	0,270
20	MLPRegressor	Red neuronal	0,712	16,80	0,714
22	RandomForestRegressor	Ensamble de árboles	0,681	17,71	0,865
25	LGBMRegressor	Ensamble de árboles	0,677	17,81	0,099
28	XGBRegressor	Ensamble de árboles	0,634	18,95	0,098
30	KNeighborsRegressor	Vecinos	0,576	20,41	0,014
36	DecisionTreeRegressor	Árbol simple	0,476	22,68	0,030
39	DummyRegressor (media)	Línea base	−0,006	31,43	0,018
42	KernelRidge	Kernel	−6,941	88,30	0,147

Lectura

Los 17 primeros puestos son modelos lineales o GLM, separados por menos de 0,007 de R^2. El mejor no lineal es Gradient Boosting (puesto 19), y los métodos kernel fallan con sus valores por defecto porque LazyPredict no centra la variable objetivo. Una sola partición no basta para decidir entre modelos tan parejos; por eso se pasa a la validación.

4. Paso 4. Validación cruzada repetida (5 particiones × 3 repeticiones)

Se reevaluaron los candidatos en las mismas 15 particiones, con el preprocesamiento de LazyPredict (estandarización). Se añadió la regresión lineal que usa **solo las 5 dummies de nacionalidad** como candidato parsimonioso.

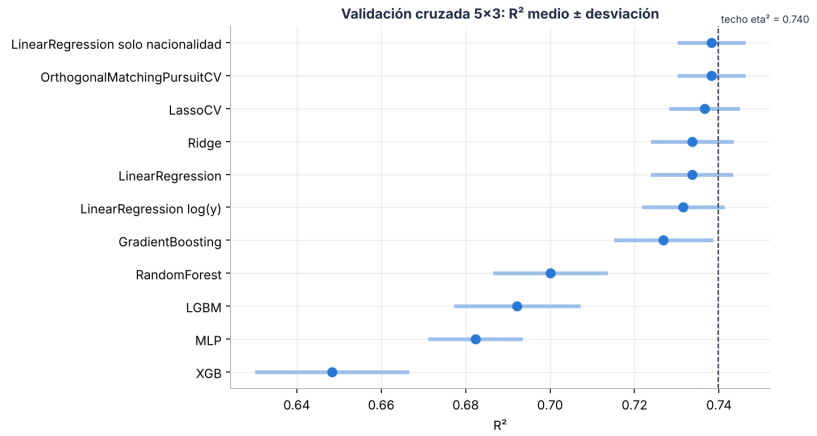


Figura 1: R^2 medio ± desviación en validación cruzada 5×3; la línea discontinua es el techo $\eta^2 = 0{,}740$

5. Paso 5. ¿Las diferencias son significativas? (Nadeau-Bengio)

Las particiones comparten datos, por lo que se usó la t corregida de Nadeau y Bengio, $t = \bar{d}/\sqrt{(1/J + n_2/n_1)\, s_d^2}$ con $J = 15$, $n_2/n_1 = 0{,}25$ y 14 gl, con ajuste de Holm, comparando cada modelo con OMP-CV. La Tabla 2 reúne los pasos 4 a 6.

Tabla 2: Validación de los candidatos. ΔR^2 = OMP-CV menos el modelo (positivo: OMP-CV es mejor)

Modelo	Var.	R^2 CV	DE	RMSE CV	ΔR^2	p Holm	R^2 2024
OrthogonalMatchingPursuitCV	28 (usa 5)	0,7382	0,0081	15,71	–	–	0,709
LinearRegression solo nacionalidad	5	0,7382	0,0081	15,71	0,0000	1,000	–
LassoCV	28	0,7365	0,0084	15,76	0,0016	0,248	0,710
LinearRegression (28 var.)	28	0,7336	0,0098	15,85	0,0046	0,036	0,708
GLM Gamma log, solo nacionalidad	5	0,7381	0,0083	–	0,0000	1,000	–
WLS (pesos $1/\hat{\sigma}_g^2$, 28 var.)	28	0,7354	0,0094	–	0,0027	0,044	–
GradientBoosting	28	0,7268	0,0118	16,05	0,0113	0,017	0,707
RandomForest	28	0,7001	0,0135	16,82	0,0381	<0,001	0,667
LGBM	28	0,6922	0,0150	17,04	0,0460	<0,001	0,678
XGB	28	0,6484	0,0182	18,20	0,0898	<0,001	0,652

Lectura

OMP-CV y la regresión solo con nacionalidad empatan ($R^2 = 0{,}7382$): al seleccionar variables, OMP-CV se queda únicamente con las cinco dummies de nacionalidad. LassoCV no difiere significativamente ($p = 0{,}248$). Los lineales con 28 variables sí son peores ($p = 0{,}036$), aunque por apenas 0,0046 de R^2 (≈0,14 soles de RMSE). Los ensambles de árboles son significativamente peores; Friedman ($\chi^2 = 159{,}9$, $p < 0{,}001$) con Nemenyi lleva a la misma conclusión. Una t pareada sin corregir habría declarado significativa incluso la diferencia con LassoCV ($p = 0{,}001$).

6. Paso 6. Robustez: tiempo, hiperparámetros, sobreajuste y modelos alternativos

- **Validación temporal** (entrenar 2019–2023, probar enero–septiembre 2024, columna R^2 2024): los lineales siguen arriba (≈ 0,71) y la caída frente a la partición aleatoria es de solo 0,02, porque el gasto no tiene tendencia.
- **Ajuste de hiperparámetros:** Gradient Boosting con `GridSearchCV` (16 combinaciones × 5 folds) elige el modelo más simple de la malla (`max_depth=2`, `learning_rate=0,03`, 300 árboles) y llega a $R^2 = 0{,}725$ en prueba. Mejora frente a su valor por defecto (0,717), pero no supera a OMP-CV y cuesta ≈13 s de búsqueda.
- **Sobreajuste:** Random Forest obtiene $R^2 = 0{,}959$ en entrenamiento y 0,681 en prueba (brecha de 0,28): memoriza el ruido. OMP-CV obtiene 0,742 y 0,730 (brecha de 0,012).
- **Modelos para la heterocedasticidad:** el GLM Gamma (enlace log) y la WLS no mejoran la predicción. Con un único predictor categórico, todos estiman la media de cada grupo; su ventaja está en la inferencia, no en el pronóstico.

7. Paso 7. Decisión: matriz de criterios

Tabla 3: Matriz de decisión entre los tres finalistas

Criterio	OMP-CV / LinReg solo nacionalidad	LassoCV	Gradient Boosting (ajustado)
Precisión (R^2 CV 5×3)	**0,7382** (techo: 0,743)	0,7365	0,7268 por defecto; 0,725 ajustado en prueba
Diferencia significativa con el mejor	–	No ($p = 0{,}248$)	Sí, es peor ($p = 0{,}017$)
Estabilidad (DE entre particiones)	**0,0081**	0,0084	0,0118
Generalización temporal 2024	0,709	0,710	0,707
Parsimonia (variables usadas)	**5**	28 (con contracción)	28
Costo (ajuste)	**0,002–0,014 s**	0,05 s	0,24 s + 13 s de búsqueda
Interpretabilidad	**Ecuación con 5 coeficientes**	Coeficientes con contracción	Caja negra

Modelo seleccionado: regresión lineal con la nacionalidad (OrthogonalMatchingPursuitCV)

Gana o empata en todos los criterios: precisión en el techo teórico, máxima estabilidad, 5 variables, el menor costo y total interpretabilidad. OMP-CV es la implementación seleccionada por LazyPredict; su forma equivalente, la regresión lineal solo con la nacionalidad, es la que se despliega en la app. Ecuación estimada (referencia: turista asiático):

$$\widehat{\text{gasto}} = 95{,}34 + 26{,}04\, D_{\text{EE.UU.}} + 16{,}34\, D_{\text{Europa}} - 15{,}44\, D_{\text{Otro}} - 30{,}28\, D_{\text{Latam}} - 50{,}27\, D_{\text{Perú}}$$

Desempeño en prueba: $R^2 = 0{,}730$; RMSE = 16,27 soles; MAE = 13,45 soles; MAPE = 15,7 % (entre 12,8 % y 17,8 % según la nacionalidad). La importancia por permutación es 1,40 para la nacionalidad y 0 para el resto.
Incertidumbre: intervalo de predicción al 95 % $= \hat{\mu}_g\,[1 - 0{,}284;\ 1 + 0{,}283]$, con los cuantiles empíricos del error relativo. Su cobertura en prueba es de 94,4 %. El intervalo normal $\pm 1{,}96 \cdot \text{CV}$ resulta demasiado ancho (cobertura de 100 %), porque el ruido es uniforme y acotado en ±30 %.

8. Conclusión y limitaciones

La selección no se basó en el primer puesto de LazyPredict, sino en la coincidencia de cinco evidencias independientes: EDA, validación cruzada, prueba de significancia corregida, validación temporal y sobreajuste. Todas apuntan al modelo más simple, que ya alcanza el R^2 máximo posible. **Limitaciones:** el dataset parece sintético (diseño balanceado, clima idéntico por sitio y ruido uniforme), por lo que el resultado ilustra el método más que la realidad turística de Puno. Para superar $R^2 \approx 0{,}74$ harían falta variables nuevas, como días de estadía, alojamiento o motivo del viaje.

Referencias: Pandala (2019), *LazyPredict*, GitHub; Pedregosa et al. (2011), *JMLR 12*, 2825–2830; Nadeau & Bengio (2003), *Machine Learning 52*(3), 239–281; Games & Howell (1976), *J. Educ. Stat. 1*(2), 113–125; Demšar (2006), *JMLR 7*, 1–30; Pati et al. (1993), *Proc. 27th Asilomar Conf.*, 40–44.

Anexos

Anexo A. Repositorio del proyecto en GitHub. En este enlace se encuentra el proyecto completo y ampliado: https://github.com/milthon-1/comparacion_de_modelos.git